

115 學年度 第 1 學期 邊緣人工智慧 Edge AI 課程綱要

課程名稱： (中文) 邊緣人工智慧 (英文) Edge AI		開課單位：		資科工碩	
		永久課號：		CSIC30166	
		上課時間/教室：		R89-ED117[GF]	
授課教師： 吳凱強					
學分數：		3.00	必 / 選修：		選修
			開課年級：		*
先修科目或先備能力： 1. Basic knowledge of neural networks 2. Python (required) and CUDA (preferred) 3. A fresh liver					
課程概述與目標： 邊緣人工智慧：邊緣人~工作的智慧？邊緣人工~的智慧？邊緣的~人工智慧！ <					

這門課將探討一系列為了實現「邊緣人工智慧」的相關技術，詳細內容請看下面的進度列表。

教科書（請註明書名、作者、出版社、出版年等資訊）：

課程大綱		分配時數				備註
單元主題	內容綱要	講授	示範	習作	其他	

教學要點概述：

1.學期作業、考試、評量：

Lab 0: Running MobileNet on the cloud (with GPU) and at the edge (without GPU)

實驗 0：在雲端（使用 GPU）和邊緣端（不使用 GPU）執行 MobileNet

Lab 1: Compressing (Pruning/Sparsifying) MobileNet

實驗 1：壓縮（剪枝/稀疏化）MobileNet

Lab 2: Running Vision Transformer and Quantizing Vision Transformer

實驗 2：運行 Vision Transformer 並量化 Vision Transformer

Lab 3: Optimizing Lab 2 with FlashAttention (and HQQ)

實驗 3：使用 FlashAttention（和 HQQ）優化實驗 2

Lab 4: Running a Large Language Model (LLM) and Compressing LLM's KV-Cache

實驗 4：運行大型語言模型 (LLM) 並壓縮 LLM 的鍵值緩存

Lab 5: Optimizing Lab 4 with PagedAttention

實驗 5：使用 PagedAttention 優化實驗 4

Lab 6: Accelerating LLM with speculative decoding

實驗 6：使用推測解碼加速 LLM

Lab 7: LLM Challenge - Joe 是要對決：奢華 LLM vs. 平價 LLM

實驗 7：LLM 挑戰賽 - Joe 是要對決：奢華 LLM vs. 平價 LLM

Lab assignments: 95%（實驗作業：95%）

Participation: 5%（課堂參與：5%）

Presentation: 5% (bonus)（演示：5%（加分））

Exam: 0% (hopefully)（考試：0%（希望如此））

2.教學方法及教學相關配合事項（如助教、網站或圖書及資料庫等）

師生晤談	排定時間	地點	聯絡方式

每週進度表			
週次	上課日期	課程進度、內容、主題	教師授課時數
1	2026-09-10(四)	Opening and introduction 開場白和介紹	
2	2026-09-17(四)	Fundamentals of artificial intelligence (AI) and deep learning (DL) 人工智慧 (AI) 和深度學習 (DL) 的基礎知識	
3	2026-09-24(四)	Review of selected neural network (NN) models: MobileNet, Transformer, LLM, etc. 精選神經網路 (NN) 模型回顧：MobileNet、Transformer、LLM 等	
4	2026-10-01(四)	Pruning: unstructured vs. structured NN model compression 剪枝：非結構化與結構化神經網路模型壓縮 Sparsity: semi-structured NN model compression 稀疏性：半結構化神經網路模型壓縮	
5	2026-10-08(四)	TinyML, ONNC	
6	2026-10-15(四)	AI accelerators (I): general-purpose AI accelerators 人工智慧加速器 (一)：通用人工智慧加速器 AI accelerators (II): TPU vs. LPU vs. NPU 人工智慧加速器 (二)：TPU、LPU 與 NPU AI accelerators (III): AI ASICs 人工智慧加速器 (三)：人工智慧專用積體電路 (ASIC)	
7	2026-10-22(四)	Quantization (I): post-training quantization 量化 (I)：訓練後量化 Quantization (II): quantization-aware training 量化 (II)：量化感知訓練 Quantization (III): MXINT vs. MXFP vs. NVFP 量化 (III)：MXINT、MXFP 和 NVFP 的比較	
8	2026-10-29(四)	Neural architecture search (I): search and train 神經架構搜尋 (I)：搜尋和訓練 Neural architecture search (II): train and search 神經架構搜尋 (II)：訓練與搜尋	

9	2026-11-05(四)	Wrap-up (halfway) 總結 (中期) What's next: LLM made faster and smaller (to be deployed at the edge) 下一步：讓 LLM 更快更小 (以便部署在邊緣) 。	
10	2026-11-12(四)	FlashAttention and PagedAttention KV-Cache (compression and quantization) KV-Cache (壓縮和量化) Google's TurboQuant vs. NVIDIA's KVTC Google 的 TurboQuant 與英偉達的 KVTC	
11	2026-11-19(四)	Speculative decoding, lookahead decoding, offloading 推測性解碼、前瞻性解碼、卸載 Speculative decoding with approximate D/V 使用近似 D/V 的推測性解碼	
12	2026-11-26(四)	P/D disaggregation (P/D 分解) D/V disaggregation (D/V 分解)	
13	2026-12-03(四)	Efficient fine-tuning: LoRA and DoRA (高效能微調：LoRA 和 DoRA) Knowledge distillation and transfer learning (知識蒸餾和遷移學習)	
14	2026-12-10(四)	LLM re-architected: Mixture-of-Experts, DeepSeek, Mamba LLM 重構：混合專家模型、DeepSeek、Mamba	
15	2026-12-17(四)	Distributed training, federated learning 分散式訓練，聯邦學習	
16	2026-12-24(四)	On-device training, privacy-aware model customization/personalization 設備端訓練、隱私感知模型客製化/個人化	

備註：

- 1.請遵守智慧財產權觀念及勿使用不法影印教科書。
- 2.其他欄包含參訪、專題演講等活動。